

# TP Statistiques 1

Charantonis Anastase & Brunel Nicolas & Julien Floquet

19 février 2018

**Rappel:** on considère que vous avez suivi l'introduction ? R: <http://tryr.codeschool.com/> dans son intégralité (d'où le QCM dans 10 minutes)

- Utilitaires et informations importantes:  
nettoyer son espace de travail: `rm(list=ls())`  
nettoyer sa console: `Ctrl +L`  
retrouver le répertoire de travail: `getwd()`  
changer d'emplacement de travail: `setwd()`
- Biblio pratique:  
<http://www3.jouy.inra.fr/miaj/public/formation/initiationRv10.pdf>
- On travaillera sous Rmarkdown. Utilisez RStudio, et créez un fichier RMarkdown. Pour les rapports on attendra un pdf et un RMarkdown avec le même nom, du type `TPSTAT1_NOM_PRENOM_GROUPE_NUMERO.format` ou les formats sont Rmd et pdf. Le dépôt pédagogique sera ouvert ? partir de la semaine prochaine. Nous allons ?valuer, pour chaque ?tudiant, 2/5 des rendus de TP choisis aléatoirement.

## Générer des données et les enregistrer

Dans cette partie on va apprendre ? générer des échantillons issus d'une loi de probabilité.

Un échantillon d'une loi de probabilité est une suite de réalisations de cette loi. Il est très utile en statistique de pouvoir générer des variables aléatoires selon diverses lois de probabilité.

R peut le faire pour un grand nombre de lois via les fonctions de la forme `rfunc(n,p1,p2,...)` où *func* indique la loi de probabilité, *n* est le nombre de variables ? générer et *p1*, *p2*, ... sont les paramètres de la loi. Pour ce faire on aura besoin de utiliser `help()` pour les fonctions suivantes:

Lois	Nom sous R
Gaussienne	<code>rnorm(n,mean=0,std=1)</code>
Uniforme	<code>runif(n,min=0,max=1)</code>
Poisson	<code>rpois(n,lambda)</code>
Exponentielle	<code>rexp(n,rate=1)</code>
$\chi^2$	<code>rchisq(n,df)</code>
Binomiale	<code>rbinom(n,size,prob)</code>
Cauchy	<code>rcauchy(n,location=0,scale=1)</code>

Retrouvez ces fonctions dans vos notes de probabilité (ou sur internet), ça va vous ?tre utile.

Pour chaque une de ces fonctions générer un échantillon de 40 données i.i.d. (indépendantes et identiquement distribuées), associez les à un vecteur inclus dans un `data.frame`, puis utilisez les fonctions `write.csv` et `write.table` pour les enregistrer. Il serait intelligent de noter les paramètres utilisés (moyenne,std,...) dans le nom de votre variable/fichier enregistré.

```
#Générer des données et les enregistrer
x1 <- rnorm(n = 40,mean=0,sd=1)
x2 <- runif(n = 40,min=0,max=1)
```

```

x3 <- rpois(n = 40, lambda = 1)
x4 <- rexp(n = 40, rate = 1)
x5 <- rchisq(n = 40, df=1)
x6 <- rbinom(n=40,size=100,prob = 0.5)
x7 <- rcauchy(n=40,location=0,scale=1)
table <- data.frame(Gaus=x1,Unif=x2,Pois=x3,Exp=x4,X2=x5,Binom=x6,Cauchy=x7)
write.csv(table,file = "data_lois.txt")
write.table(table,file = "table_lois.txt")

```

## Charger des données depuis un fichier txt (texte) et csv (comma separated variables)

Nettoyez votre espace de travail. Utilisez les fonctions `read.csv` et `read.table`, pour charger la distribution Gaussienne que vous avez genere. Que remarquez-vous?

Pensez ? utiliser `header=TRUE`.

```

#Charger des donn??es depuis un fichier txt (texte) et csv (comma separated variables)
read.csv("data_lois",header = TRUE)

```

##	X	Gaus	Unif	Pois	Exp	X2	Binom
## 1	1	-2.228868934	0.247995576	2	0.79786548	1.5617828169	51
## 2	2	0.908721294	0.093036140	0	0.63683605	0.0260895737	44
## 3	3	-1.051628341	0.841059783	0	0.03464805	0.9537782182	50
## 4	4	-0.525118785	0.990921913	1	0.24510577	1.1958655367	52
## 5	5	0.685228455	0.938198705	6	0.20054450	0.8367666393	55
## 6	6	0.256227309	0.786460882	1	1.69939544	2.6047733862	48
## 7	7	-0.098132848	0.048130236	3	0.51424575	1.8203204859	44
## 8	8	-1.283168389	0.019140818	1	0.16007431	0.0092037689	40
## 9	9	0.009362496	0.957550047	0	3.41333091	1.8389479200	53
## 10	10	-0.835433535	0.643353435	1	0.25023203	8.8022177292	45
## 11	11	-1.041441615	0.176544573	0	2.08874663	0.0117207012	55
## 12	12	0.306095916	0.119803840	2	1.29389027	0.5396117805	49
## 13	13	0.352313317	0.116436709	1	0.41187973	0.4819901175	50
## 14	14	-1.389996191	0.005084943	2	1.19406126	2.7187165586	55
## 15	15	0.049227193	0.209420965	1	0.71986785	0.4119801107	45
## 16	16	0.756708248	0.317003883	0	0.54803382	0.2577920238	47
## 17	17	0.829702761	0.794511886	2	0.07749803	2.0054031216	49
## 18	18	0.664739641	0.639865536	1	1.59505588	0.0115381643	47
## 19	19	0.935674302	0.510153611	1	1.05843008	0.6252343602	49
## 20	20	0.629676781	0.964004045	1	3.72422027	0.1878691079	55
## 21	21	0.299217923	0.757314341	1	0.07940264	0.0453727651	51
## 22	22	-1.084006039	0.376431122	0	5.29677455	1.2688167985	47
## 23	23	-0.114739193	0.122295106	1	0.96985305	0.0040966674	50
## 24	24	-0.938622085	0.907518429	0	0.73154425	0.0800121451	52
## 25	25	0.319173813	0.486942126	1	2.08433234	0.0189747882	53
## 26	26	0.079417371	0.977081300	1	1.16148740	4.2128039660	54
## 27	27	0.774205602	0.284898989	2	2.14170399	1.4512905679	48
## 28	28	-0.166453310	0.175979580	1	4.79693659	1.0936768307	59
## 29	29	1.585286284	0.494086588	1	0.44535271	3.1650373468	50
## 30	30	-0.520959005	0.055898370	1	0.63433364	3.5860950223	52
## 31	31	-2.844184604	0.382720170	0	0.84994370	0.4336873709	51
## 32	32	1.740987165	0.189425094	0	0.38251150	0.0006922237	44
## 33	33	-1.755336750	0.661384995	0	3.00414363	0.3448986815	51
## 34	34	-0.805662397	0.954114778	4	3.54012160	0.0472298031	49

```
## 35 35 0.668190822 0.229574132 1 0.14056230 4.6830013228 48
## 36 36 0.831036215 0.725698940 0 0.02251692 0.2457625441 43
## 37 37 0.211070411 0.353101630 1 1.96754159 0.0661977086 44
## 38 38 0.420408476 0.296922152 1 0.63338295 1.4797658615 48
## 39 39 -0.600749033 0.795569010 1 0.35407606 2.6692185695 56
## 40 40 -2.413129186 0.856200660 0 0.23249515 0.7347440077 58
##      Cauchy
## 1      1.16315726
## 2     -3.00571324
## 3     -0.78941402
## 4      0.64063649
## 5     -1.76193592
## 6      0.22560521
## 7      1.31106714
## 8     -0.81207933
## 9      0.38964118
## 10     1.73276639
## 11     0.53438741
## 12    -1.46150740
## 13    -0.56088739
## 14     3.73126369
## 15     3.12771761
## 16   -11.39943011
## 17     0.66846214
## 18     0.07623950
## 19     1.67341615
## 20    -2.72292985
## 21    -0.57529690
## 22     1.39793799
## 23    -0.32314444
## 24    -0.14125489
## 25     0.16775494
## 26    -0.48811745
## 27     1.61484641
## 28     2.50056176
## 29    -0.05380677
## 30    -3.98479654
## 31     0.56716772
## 32     0.34614380
## 33     1.50888925
## 34    -1.18601747
## 35     0.03298123
## 36    -0.56009778
## 37    -0.39055069
## 38    -0.30461188
## 39    -0.45299059
## 40     0.50792347
```

```
read.table("table_lois",header = TRUE)
```

##	Gaus	Unif	Pois	Exp	X2	Binom
## 1	-2.228868934	0.247995576	2	0.79786548	1.5617828169	51
## 2	0.908721294	0.093036140	0	0.63683605	0.0260895737	44
## 3	-1.051628341	0.841059783	0	0.03464805	0.9537782182	50
## 4	-0.525118785	0.990921913	1	0.24510577	1.1958655367	52

## 5	0.685228455	0.938198705	6	0.20054450	0.8367666393	55
## 6	0.256227309	0.786460882	1	1.69939544	2.6047733862	48
## 7	-0.098132848	0.048130236	3	0.51424575	1.8203204859	44
## 8	-1.283168389	0.019140818	1	0.16007431	0.0092037689	40
## 9	0.009362496	0.957550047	0	3.41333091	1.8389479200	53
## 10	-0.835433535	0.643353435	1	0.25023203	8.8022177292	45
## 11	-1.041441615	0.176544573	0	2.08874663	0.0117207012	55
## 12	0.306095916	0.119803840	2	1.29389027	0.5396117805	49
## 13	0.352313317	0.116436709	1	0.41187973	0.4819901175	50
## 14	-1.389996191	0.005084943	2	1.19406126	2.7187165586	55
## 15	0.049227193	0.209420965	1	0.71986785	0.4119801107	45
## 16	0.756708248	0.317003883	0	0.54803382	0.2577920238	47
## 17	0.829702761	0.794511886	2	0.07749803	2.0054031216	49
## 18	0.664739641	0.639865536	1	1.59505588	0.0115381643	47
## 19	0.935674302	0.510153611	1	1.05843008	0.6252343602	49
## 20	0.629676781	0.964004045	1	3.72422027	0.1878691079	55
## 21	0.299217923	0.757314341	1	0.07940264	0.0453727651	51
## 22	-1.084006039	0.376431122	0	5.29677455	1.2688167985	47
## 23	-0.114739193	0.122295106	1	0.96985305	0.0040966674	50
## 24	-0.938622085	0.907518429	0	0.73154425	0.0800121451	52
## 25	0.319173813	0.486942126	1	2.08433234	0.0189747882	53
## 26	0.079417371	0.977081300	1	1.16148740	4.2128039660	54
## 27	0.774205602	0.284898989	2	2.14170399	1.4512905679	48
## 28	-0.166453310	0.175979580	1	4.79693659	1.0936768307	59
## 29	1.585286284	0.494086588	1	0.44535271	3.1650373468	50
## 30	-0.520959005	0.055898370	1	0.63433364	3.5860950223	52
## 31	-2.844184604	0.382720170	0	0.84994370	0.4336873709	51
## 32	1.740987165	0.189425094	0	0.38251150	0.0006922237	44
## 33	-1.755336750	0.661384995	0	3.00414363	0.3448986815	51
## 34	-0.805662397	0.954114778	4	3.54012160	0.0472298031	49
## 35	0.668190822	0.229574132	1	0.14056230	4.6830013228	48
## 36	0.831036215	0.725698940	0	0.02251692	0.2457625441	43
## 37	0.211070411	0.353101630	1	1.96754159	0.0661977086	44
## 38	0.420408476	0.296922152	1	0.63338295	1.4797658615	48
## 39	-0.600749033	0.795569010	1	0.35407606	2.6692185695	56
## 40	-2.413129186	0.856200660	0	0.23249515	0.7347440077	58
##	Cauchy					
## 1	1.16315726					
## 2	-3.00571324					
## 3	-0.78941402					
## 4	0.64063649					
## 5	-1.76193592					
## 6	0.22560521					
## 7	1.31106714					
## 8	-0.81207933					
## 9	0.38964118					
## 10	1.73276639					
## 11	0.53438741					
## 12	-1.46150740					
## 13	-0.56088739					
## 14	3.73126369					
## 15	3.12771761					
## 16	-11.39943011					
## 17	0.66846214					

```
## 18 0.07623950
## 19 1.67341615
## 20 -2.72292985
## 21 -0.57529690
## 22 1.39793799
## 23 -0.32314444
## 24 -0.14125489
## 25 0.16775494
## 26 -0.48811745
## 27 1.61484641
## 28 2.50056176
## 29 -0.05380677
## 30 -3.98479654
## 31 0.56716772
## 32 0.34614380
## 33 1.50888925
## 34 -1.18601747
## 35 0.03298123
## 36 -0.56009778
## 37 -0.39055069
## 38 -0.30461188
## 39 -0.45299059
## 40 0.50792347
```

*# si on utilise read.csv, il y aura des virgules entre chque data on a stocké.*

## Tracer les données

Genrez un vecteur qui contient 10 rralisations de la loi normale  $N(0,1)$ . Tracez les points obtenus en utilisant ‘plot’, et m?ttant sur l’axe des x un vecteur sequentiel de la taille de votre vecteur.

Que remarquez-vous? (Utiliez la commande ‘abline(h=0)’)

Tracez ?galement les lignes horizontales 1 et -1. Que remarquez-vous? Combien de points sont en dehors de ces lignes? La m?me chose avec les lignes horizontales 2 et -2, 3 et -3. Que remarquez vous?

Effectuer la même chose avec des vecteurs contenant 100 et 1000 valeurs. Que remarquez vous?


Chargez le fichier ‘distribution\_inconue\_1\_100\_realisations.csv’ que vous pouvez trouver dans le même emplacement que ce fichier.

Est-ce que vous pouvez conclure quelque chose sur cette distribution, à partir d’une visualisation?

Testez avec d’autres distributions. Que remarquez-vous?


```
#Tracer les données
y <- rnorm(n = 10,mean=0,sd=1)
plot(y,main = "Gaussienne",ylim = c(-5,5))
axis(1,at=seq(1,10,1))
abline(h=c(0,1,-1,2,-2,3,-3),col = ("blue"))
```

## Gaussienne




```
# tous les 10 points sont proche de 0, en plus ils sont tous entre [-1,1], et il n'y a pas  
# beaucoup de données aberrantes  
y1 <- rnorm(n = 100, mean = 0, sd = 1)  
plot(y1, main = "Gaussienne", ylim = c(-5, 5), xaxt = "n")  
axis(1, at = seq(0, 100, 10))  
abline(h = c(0, 1, -1, 2, -2, 3, -3), col = "red")
```

## Gaussienne



```
# tous les 100 sont tous entre [-3,3], leur degree de dispersion est plus grand que celle de  
# 10 point  
y2 <- rnorm(n = 1000, mean = 0, sd = 1)  
plot(y2, main = "Gaussienne", ylim = c(-5, 5), xaxt = "n")  
axis(1, at = seq(0, 1000, 50))  
abline(h = c(0, 1, -1, 2, -2, 3, -3), col = ("green"))
```


## Gaussienne



```
# il y a des point dont valeur est superieur que 3 ou moins que -3, c'est à dire si on
# effectue beaucoup de fois d'echantillon , il y aura surement des point aberrantes.
# par contre , pluspart de point se concentrent sur l'esperance
Data <- read.csv("distribution_inconue_1_100_realisations.csv", header=TRUE)
x <- unlist(Data[2])
plot(x,main ="inconnu",ylim = c(-10,10),xaxt="n")
axis(1,at=seq(0,100,10))
abline(h=c(0,1,-1,4,-4,7,-7),col = ("yellow"))
```




## inconnu




```
# j'ai remarqué pluspart presque 80% de point se situent entre [-4,4], il n'y a pas beaucoup  
# de point aberrantes, sa distribution ressemble à celle de Gaussien  
x1 <- rpois(n = 100, lambda = 1)  
plot(x1, main = "Poisson", ylim = c(-5, 5), xaxt = "n")  
axis(1, at = seq(0, 100, 10))  
abline(h = c(0, 1, -1, 2, -2, 3, -3), col = ("orange"))
```

## Poisson

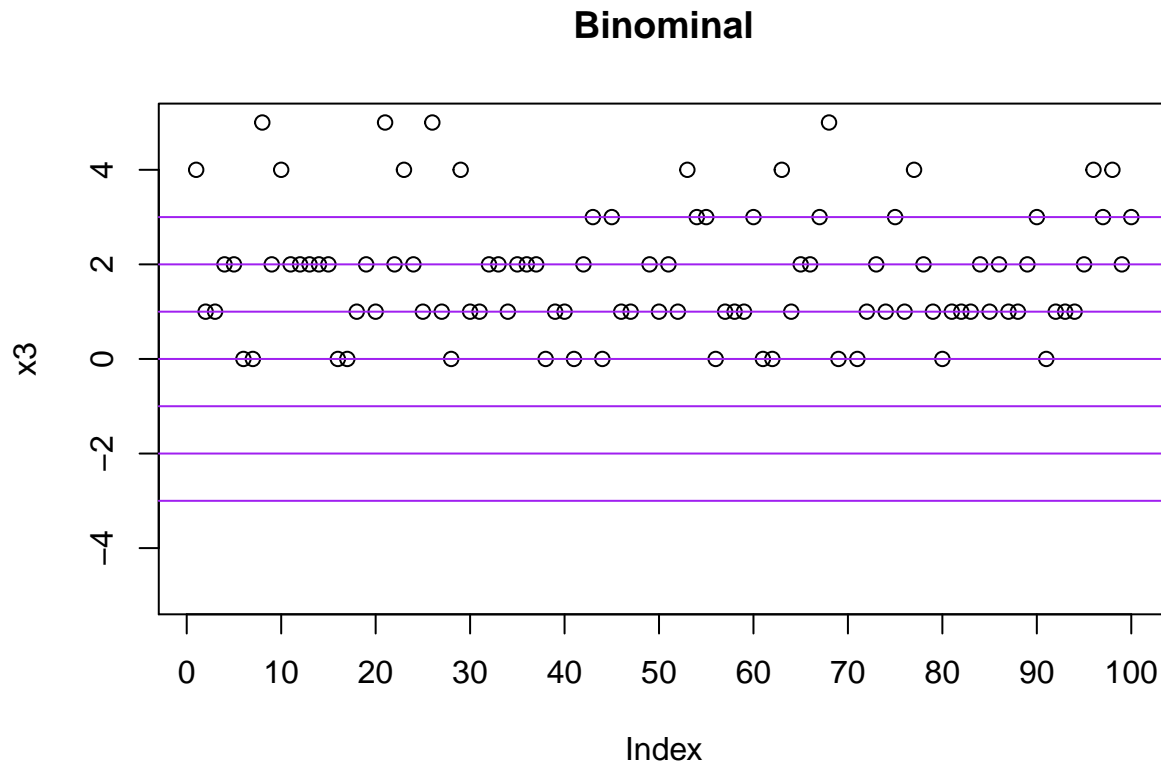


```
x2 <- rexp(n = 100, rate = 2)
plot(x2, main = "Exponentielle", ylim = c(-5, 5), xaxt = "n")
axis(1, at = seq(0, 100, 10))
abline(h = c(0, 1, -1, 2, -2, 3, -3), col = ("black"))
```

## Exponentielle



```
x3 <- rbinom(n=100,size=100,prob = 0.02)
plot(x3,main = "Binominal",ylim = c(-5,5),xaxt="n")
axis(1,at=seq(0,100,10))
abline(h=c(0,1,-1,2,-2,3,-3),col= ("purple"))
```



*#j'ai remarqué que pluspart de point sont proche de leur esperence, et plus la variance est grande, plu*

## Histogrammes

La visualisation des r?sultats precedents nous donnent certaines informations sur la distribution dont ils sont issus.

Les histogrammes sont une autre fa?on d'?valuer visuellement les donn?es d'un echantillon. Ils representent la densit? de distribution de valeurs de r?alisations de notre echantillon par segments.

Utilisez `help()` pour la fonction `hist()`.

Appliquez la fonction pour l'echantillon de 100 r?alisations que vous avez cr??, et pour 'distribution\_inconnue\_1\_100\_realisations.csv'. Que remarquez vous?

Testez les differents param??trages de la fonction: `breaks` et `freq`.

Effectuez la m?me chose pour des distributions de Cauchy avec des parametrages differents.

Par ailleurs, regardez les fonctions de type `dfunc(n,p1,p2,...)`. Elles peuvent vous donner la distribution th?orique que vous devriez obtenir. Superposez deux plots en utilisant `par(new=TRUE)` puis en plottant la distribution correspondante au histogramme que vous visualisez.


```
#Histogrammess
# quand j'ai mis seq(-5,5,2), les deux Histogrammes
# ont pas la meme form , pourquoi?
x1 <- rnorm(n = 100,mean=0,sd=1)
```

```

x2 <- runif(n = 100,min=0,max=1)
x3 <- rpois(n = 100,lambda = 1)
x4 <- rexp(n = 100, rate = 1)
x5 <- rchisq(n = 100, df=1)
x6 <- rbinom(n=100,size=100,prob = 0.5)
x7 <- rcauchy(n=100,location=0,scale=1)
Data <- read.csv("distribution_inconue_1_100_realisations.csv", header=TRUE)
x8 <- unlist(Data[2])
table <- data.frame(Gaus=x1,Unif=x2,Pois=x3,Exp=x4,X2=x5,Binom=x6,Cauchy=x7,Inconnu=x8)
write.table(table,file = "data_8_lois.txt")
x <- seq(-5,5,0.01)
z1 <- dnorm(x,0,1)
hist(x1, seq(-5,5,1),freq = T,main ="Gaussien",xlim = c(-5,5),ylim = c(0,100))

```

## Gaussien




```

hist(x1, seq(-5,5,1),freq = F,main ="Gaussien",xlim = c(-5,5),ylim = c(0,1))
par(new=TRUE)
plot(x,z1,xlim = c(-5,5),type='l',ylim = c(0,1),xlab="",ylab="",yaxt="n",xaxt="n")


```

## Gaussien




```
hist(x2,breaks = seq(-5,5,1),freq = T,ylim = c(0,100),main ="Uniform")
```


## Uniform



```
hist(x2,breaks = seq(-5,5,1),freq = F,ylim = c(0,1),main ="Uniform")
par(new=TRUE)
z2 <- dunif(x,0,1)
plot(x,z2,xlim = c(-5,5),type='l',ylim = c(0,1),xlab="",ylab="",yaxt="n",xaxt="n")
```




```
hist(x3, breaks = seq(0,10,1),freq = T,ylim = c(0,100),main = "Poisson")
```



```
hist(x3, breaks = seq(0,10,1),freq = F,ylim = c(0,1),main = "Poisson")  
par(new=TRUE)
```


```
k <- seq(0,100,1)
z3 <- dpois(k,lambda = 1)
plot(k,z3,xlim = c(0,10),type='l',ylim = c(0,1),xlab="",ylab="",yaxt="n",xaxt="n")
```

## Poisson




```
hist(x4, breaks = seq(-10,10,1),freq = T,ylim = c(0,100),main = "Exponentielle")
```

## Exponentielle




```
hist(x4, breaks = seq(-10,10,1),freq = F,ylim = c(0,1),main = "Exponentielle")
par(new=TRUE)
z4 <- dexp(x,rate = 1)
plot(x,z4,xlim = c(-10,10),type='l',ylim = c(0,1),xlab="",ylab="",yaxt="n",xaxt="n")
```

## Exponentielle



```
hist(x5, breaks = seq(-10,10,1),freq = T,ylim = c(0,100),main = "X2")
```






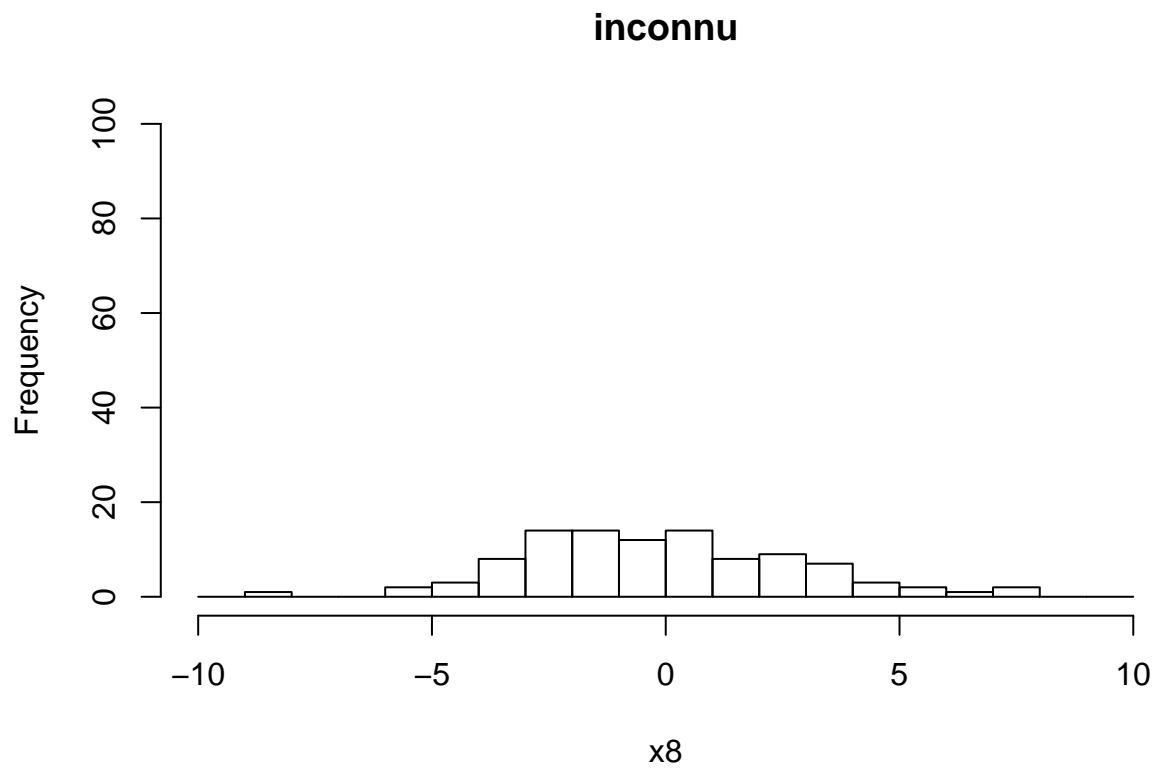
```

x5
hist(x5, breaks = seq(-10,10,1),freq = F,ylim = c(0,1),main = "X2")
par(new=TRUE)
z5 <- dchisq(x,df=1)
plot(x,z5,xlim = c(-10,10),type='l',ylim = c(0,1),xlab="",ylab="",yaxt="n",xaxt="n")


```



```
hist(x8, breaks = seq(-10,10,1),freq = T,ylim = c(0,100),main = "inconnu")
```



```
hist(x8, breaks = seq(-10,10,1),freq = F,ylim = c(0,1),main = "inconnu")
```



# Le histogramme de "inconnu" ressemble beaucoup à celui de Gaussien

## Moments d'ordre

Les moments d'ordre élevé pour une distribution nous donnent des informations liés à la forme des écart à la moyenne. Si on connaît notre loi analytiquement, on peut calculer ses moments. Mais quand on a seulement un échantillon i.i.d. d'une loi inconnue, nous devons les estimer.

- Empiriquement:  
Skewness négatif → plus notre densité est dissymétrique vers la gauche.  
Kurtosis petit → Plus l'extrémité de la densité va tendre rapidement vers 0.

Sous R il existe les fonctions `skewness()` et `kurtosis()`. Calculez les moments des 4 premiers ordres pour les échantillons que vous avez générés et stockez les résultats dans une matrice. Commentez les résultats obtenus et comparez les valeurs théoriques de ces distributions.

Moment	Ordre	Formule	Estimateur
Moyenne	1	$E[X] = \int_{-\infty}^{\infty} x dF(x)$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
Variance	2	$E[X^2] = \int_{-\infty}^{\infty} x^2 dF(x)$	$\sigma_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$
Skewness	3	$E[X^3] = \int_{-\infty}^{\infty} x^3 dF(x)$	$b_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{[\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2]^{3/2}}$
Kurtosis	4	$E[X^4] = \int_{-\infty}^{\infty} x^4 dF(x)$	$g_2 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2]^2} - 3$

```
library(fBasics)
```

```
## Loading required package: timeDate
```

```
## Loading required package: timeSeries
```

```
table <- read.table("data_8_lois.txt",header = TRUE)
```

```
x1 <- unlist(table[1])
```

```
x2 <- unlist(table[2])
```

```
x3 <- unlist(table[3])
```

```
x4 <- unlist(table[4])
```

```
x5 <- unlist(table[5])
```

```
x6 <- unlist(table[6])
```

```
x7 <- unlist(table[7])
```

```
x8 <- unlist(table[8])
```

```
noms <- c("Gus", "Unif", "Pois", "Exp", "X2", "Binom", "Cauchy", "Inconnu")
```

```
Mean <- c(mean(x1), mean(x2), mean(x3), mean(x4), mean(x5), mean(x6), mean(x7), mean(x8));
```

```
Var <- c(var(x1), var(x2), var(x3), var(x4), var(x5), var(x6), var(x7), var(x8));
```

```
Skewness <- c(skewness(x1), skewness(x2), skewness(x3), skewness(x4), skewness(x5), skewness(x6), skewness(x7), skewness(x8));
```

```
Kurtosis <- c(kurtosis(x1), kurtosis(x2), kurtosis(x3), kurtosis(x4), kurtosis(x5), kurtosis(x6), kurtosis(x7), kurtosis(x8));
```

```
m <- data.frame(noms, Mean, Var, Skewness, Kurtosis)
```

```
print(m)
```

##	noms	Mean	Var	Skewness	Kurtosis
## 1	Gus	0.1087425	0.72736061	0.2557791	-0.1934165
## 2	Unif	0.5113430	0.07672447	-0.0954954	-1.1078875
## 3	Pois	0.9700000	1.10010101	1.2029706	1.4047146
## 4	Exp	0.9669590	0.65984079	1.1072391	0.8239690
## 5	X2	0.8367383	0.95480864	2.3496152	7.5459274
## 6	Binom	49.5200000	25.90868687	0.2677199	0.4852014
## 7	Cauchy	-0.4856826	39.07056759	-1.8903425	15.0152373
## 8	Inconnu	-0.1143862	8.34430091	0.1883106	0.0180116

## Quantiles et Boxplot

Les moments (surtout de premier et second ordre) peuvent nous donner beaucoup d'informations sur les lois dont sont issus nos échantillons. Une autre façon de considérer cela correspond à ordonner nos données dans l'échantillon et de les évaluer en estimant quelle quantité de données sont inférieures ou supérieures à une valeur.

q-Quantile: si on segmente notre distribution de densité de probabilités en  $q$  parts de volume égal, la valeur en dessous de la quelle se situent  $p/q$  des données est nommée  $p$ -ème quantile. Typiquement on travaille avec des segmentations de notre distribution en quatre ou cent morceaux. Formellement :

Le quantile  $x_{\frac{p}{q}}$  d'une variable aléatoire  $X$  est défini comme:  $P(X \leq x_{\frac{p}{q}}) = \frac{p}{q}$

où de façon équivalente:  $P(X \geq x_{\frac{p}{q}}) = 1 - \frac{p}{q}$ .

Comme avant, entre connaître la distribution réelle et essayer de "faire parler les données", il y a une grande différence. On s'appuie sur notre échantillon pour essayer d'avoir plus d'informations sur nos distributions.

- Quantiles spécifiques:
  - $Q_1$ : La valeur en dessous de la quelle on a le quart des valeurs de notre échantillon.
  - $Q_2$ : La valeur en dessous de la quelle on a la moitié des valeurs de notre échantillon, aussi connue sous le nom de médiane.
  - $Q_3$ : La valeur en dessous de la quelle on a les trois-quarts des valeurs de notre échantillon.


Le boxplot nous permet de voir les valeurs entre  $Q_1$  et  $Q_2$ , et  $Q_2$  et  $Q_3$ , ainsi que la moyenne et l'écart de  $\pm 3\sigma$ . Toute valeur en dehors de ces  $\pm 3\sigma$  est marquée avec des points individuels.

Regardez l'aide de la fonction `boxplot()` et appliquez la sur les différents ensembles que vous avez générés. Pour le tableau précédent, contenant les moments de ordre 1 à 4, ajoutez 3 colonnes qui contiennent les 3 quantiles.

```
#Quantiles et Boxplot
table <- read.table("data_8_lois.txt",header = TRUE)

x1 <- table[1]
x2 <- table[2]
x3 <- table[3]
x4 <- table[4]
x5 <- table[5]
x6 <- table[6]
x7 <- table[7]
x8 <- table[8]
boxplot(unlist(x1),main = "Gaussien")
```


## Gaussien



```
c1<-quantile(unlist(x1),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x2),main ="Uniform")
```


## Uniform



```
c2<-quantile(unlist(x2),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x3),main ="Poisson")
```


## Poisson



```
c3<-quantile(unlist(x3),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x4),main ="Exponentielle")
```


## Exponentielle



```
c4<-quantile(unlist(x4),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x5),main ="X2")
```


## X2



```
c5<-quantile(unlist(x5),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x6),main ="Binonim")
```


## Binonim



```
c6<-quantile(unlist(x6),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x7),main ="Cauchy")
```


## Cauchy



```
c7<-quantile(unlist(x7),c(0.25,0.5,0.75))
```

```
boxplot(unlist(x8),main="inconnu")
```

## inconnu



```
c8<-quantile(unlist(x8),c(0.25,0.5,0.75))
```

```
q<-data.frame(Gaus=c1,Unif=c2,Pois=c3,Exp=c4,X2=c5,Binom=c6,Cauchy=c7,Inconnu=c8)
```

```
rownames(q)<- c("Q1","Q2","Q3")
```

```
Q <-t(q)
```

```
Table_info_loi <-cbind(m,Q)
```

```
print(Table_info_loi)
```

##	noms	Mean	Var	Skewness	Kurtosis	Q1
## Gaus	Gus	0.1087425	0.72736061	0.2557791	-0.1934165	-0.4953322
## Unif	Unif	0.5113430	0.07672447	-0.0954954	-1.1078875	0.3091710
## Pois	Pois	0.9700000	1.10010101	1.2029706	1.4047146	0.0000000




```
## Exp      Exp  0.9669590  0.65984079  1.1072391  0.8239690  0.2818774
## X2      X2  0.8367383  0.95480864  2.3496152  7.5459274  0.1874066
## Binom    Binom 49.5200000 25.90868687  0.2677199  0.4852014 46.7500000
## Cauchy   Cauchy -0.4856826 39.07056759 -1.8903425 15.0152373 -1.2818906
## Inconnu  Inconnu -0.1143862 8.34430091  0.1883106  0.0180116 -2.1959296
##          Q2      Q3
## Gaus     0.12820361 0.6989595
## Unif     0.53182033 0.7415278
## Pois     1.00000000 1.0000000
## Exp      0.79845034 1.4256436
## X2      0.57375450 1.1432138
## Binom    49.00000000 53.0000000
## Cauchy   -0.04141784 0.8435802
## Inconnu  -0.24532650 1.8832830
```


## Interprétation visuelle

Générez 3 ensembles de 100 individus avec la loi de Cauchy avec des paramétrisations différentes. Effectuez toutes les démarches vues dans ce TP. Que remarquez-vous?


```
#Interprétation visuelle
cau1 <- rcauchy(n=100,location=0,scale=1)
cau2 <- rcauchy(n=100,location=0,scale=0.5)
cau3 <- rcauchy(n=100,location=-2,scale=2)
x <- seq(-5,4.9,0.1)
plot(cau1,ylim=c(-10,10))
abline(h=c(0,2,-2,4,-4,6,-6),col= ("purple"))
```



```
plot(cau2,ylim=c(-10,10))
abline(h=c(0,2,-2,4,-4,6,-6),col= ("purple"))
```




```
plot(cau3,ylim=c(-10,10))
abline(h=c(0,2,-2,4,-4,6,-6),col= ("purple"))
```




```
rcauc1 <-dcauchy(x,location = 0,scale=1)
plot(x,rcauc1,ylim = c(0,1),main ="Cauchy_0,1")
```

### Cauchy\_0,1




```
rcauc2 <-dcauchy(x,location = 0,scale=0.5)
plot(x,rcauc2,ylim = c(0,1),main ="Cauchy_0,0.5")
```

### Cauchy\_0,0.5




```
rcauc3 <-dcauchy(x,location = -2,scale=2)
plot(x,rcauc3,ylim = c(0,1),main ="Cauchy_-2,2")
```

## Cauchy\_-2,2




```
boxplot(cau1,ylim=c(-10,10),main="box_Cauchy_0,1")
```

## box\_Cauchy\_0,1




```
boxplot(cau2,ylim=c(-10,10),main="box_Cauchy_0,0.5")
```

## box\_Cauchy\_0,0.5



```
boxplot(cau3,ylim=c(-10,10),main="box_Cauchy_-2,2")
```

## box\_Cauchy\_-2,2



```
library(fBasics)
noms = c("cau1 ", "cau2 ", "cau3 ")
moyenne <- c(mean(cau1), mean(cau2), mean(cau3))
variance<- c(var(cau1), var(cau2), var(cau3))
Skewness <- c(skewness(cau1), skewness(cau2), skewness(cau3))
Kurtosis<- c(kurtosis(cau1), kurtosis(cau2), kurtosis(cau3))
f <- data.frame(noms,moyenne, variance, Skewness, Kurtosis)
print(f)
```

```
##      noms      moyenne  variance  Skewness  Kurtosis
## 1 cau1  -0.9118985  23.42896 -3.510952  21.92019
## 2 cau2   3.6057151 503.30601  6.655213  49.13554
## 3 cau3  -2.9407181 336.16021  2.610133  29.36037
```

*#j'ai remarqué que le degré de dispersion des points de #distribution Cauchy sont tres élevés, surtout ;  
#les distribution qui ont un petite sacle .Par contre,  
# plus le sacle est petite, plus la distribution Cauchy est #centrée sur 0, c'est à dire que sa Var est*